Arbetsplan datareduktion översikt

Dataset	Vinkel	Tekniker	Leverans
WHR 2019-2025	Vinnare & förlorare över tid	PCA + UMAP	6 slides, 10 min

1	Förstå & städa data	Krav: välj dataset + undersök variabler
2	Deskriptiv statistik	Krav: köra statistik på variabler
3	Visualisera rådata	Krav: visualisera data
4	Datareduktion — PCA	Krav: använd datareduktionsteknik
5	Datareduktion — UMAP	Krav: en eller flera tekniker
6	Bygg presentationen	Krav: 5-7 bilder, berättelse

Huvudfråga:

Vilka länder är vinnare respektive förlorare över tidsperioden 2019-2025 i World Happiness Report?

Bifråga 1:
Finns det geografiska eller regionala mönster bland de länder som förbättrats respektive försämrats?

Bifråga 2:
Vilken av de sex lyckofaktorerna (BNP, socialt stöd, hälsa, frihet, generositet, korruption) bidrar mest till att skilja vinnare från förlorare, och är det samma faktorer som PCA och UMAP lyfter fram som viktigast?

Arbetsplan datareduktion step by step

Steg 1

1 Förstå & städa data

Krav: välj dataset + undersök variabler

- Läs in WHR26_raw_file.xlsx med pandas
  Kolla .shape, .dtypes, .head() — bekanta er med strukturen
- Filtrera ut åren 2019–2025 (de enda med kompletta värden)
  143 länder har data för båda åren — det är er analysbas
- Hantera saknade värden
  Droppa rader med NaN i de 6 förklarande variablerna — enkelt och försvarbart
- Dokumentera vilka variabler ni väljer att fokusera på
  De 6 komponenterna: BNP, socialt stöd, hälsa, frihet, generositet, korruption

Steg 2

2 Deskriptiv statistik

Krav: köra statistik på variabler

- Kör df.describe() på de 6 variablerna
  Medelvärde, standardavvikelse, min/max — lägg in i presentationen
- Bygg en korrelationsmatris (heatmap)
  Visar om variablerna hänger ihop — motiverar varför PCA är relevant
- Beräkna förändring i lyckopoäng per land 2019→2025
  Vi har redan gjort detta — Viet Nam +1.07, Afghanistan -1.12 osv.

Steg 3

3 Visualisera rådata

Krav: visualisera data

- Stapeldiagram: topp 10 vinnare & förlorare 2019→2025
  Redan klar som interaktiv visualisering — ni kan använda den direkt
- Tidslinje för utvalda länder
  Visa t.ex. Afghanistan, Libanon, Viet Nam, Serbien — dramatiska berättelser
- Världskarta färgad efter förändring (valfritt men snyggt)
  Grön = förbättring, röd = försämring — ger direkt geografisk känsla

Steg 4

4 Datareduktion — PCA

Krav: använd datareduktionsteknik

- ⚖️ Standardisera de 6 variablerna med StandardScaler
  Obligatoriskt enligt föreläsningen — annars styr BNP allt
- 🔄 Kör PCA med sklearn.decomposition.PCA
  Reducera 6 dimensioner → 2 huvudkomponenter
- 📐 Plotta Scree plot (elbow-kurva)
  Visa hur mycket variation PC1 och PC2 förklarar — krävs för att motivera valet av 2 komponenter
- 🎯 Scatter plot: länder i PCA-rummet, färgade efter förändring
  Vinnare i en färg, förlorare i en annan — kopplar PCA till er vinkel
- 🔎 Undersök variabelbidrag (loadings)
  Vilket av de 6 faktorerna påverkar PC1 och PC2 mest? EXTRA-poäng!

Steg 5

5 Datareduktion — UMAP

Krav: en eller flera tekniker

- 📦 Installera umap-learn (pip install umap-learn)
  Inte i sklearn — eget paket
- 📂 Kör UMAP på samma standardiserade data
  Samma input som PCA — bra att jämföra resultaten
- 🎛️ Testa hyperparametrar: n_neighbors & min_dist
  Prova 5, 15, 30 neighbors — visa hur klustren förändras. EXTRA-poäng!
- 🎨 Scatter plot: länder i UMAP-rummet, färgade efter förändring
  Jämför med PCA-plotten — ser ni samma mönster?

Steg 6

6 Bygg presentationen

Krav: 5–7 bilder, berättelse

1. **Introduktion** — Vad är WHR? Vilka variabler? Vår fråga: "Vad skiljer vinnare från förlorare?"
2. **Deskriptiv statistik** — Korrelationsmatris + global förändring 2019→2025
3. **Vinnare & förlorare** — Stapeldiagram + tidslinjer för de dramatiska fallen
4. **PCA-resultat** — Scree plot + scatter plot + vilka faktorer driver förändringen?
5. **UMAP-resultat** — Kluster av länder, hyperparameterjämförelse, kontrast mot PCA
6. **Slutsatser** — Vad lärde vi oss? Vad är begränsningarna? Vad är nästa fråga?